ECG Anomali Tespiti için CNN-VAE ve Ansamble Derin Öğrenme Yaklaşımı

Özet (Abstract)
Bu çalışmada, MIT-BIH Long-Term Arrhythmia veri tabanından elde edilen tek kanallı (MLII) elektrokardiyogram (ECG) sinyalleri üzerinde otomatik anomali tespiti gerçekleştirilmiştir. [2] Ham sinyal öncelikle 5–50 Hz bant geçiren Butterworth filtresi ile gürültüden arındırılmış, ardından Pan–Tompkins yaklaşımına benzer bir türev–kare alma–kayan ortalama yapısı kullanılarak R–peak'ler tespit edilmiştir. Her bir R–peak etrafında 0.2 s öncesi ve 0.4 s sonrası olacak şekilde sabit uzunlukta beat segmentleri çıkarılmış; fizyolojik RR aralıkları, genlik varyansı ve enerji tabanlı ek maskeleme adımları ile yalnızca istatistiksel olarak "normal" kabul edilen beat'ler eğitim için seçilmiştir.
Ana model olarak, 1-B konvolüsyon katmanları ile ECG beat'lerinden latent temsil öğrenen bir CNN-VAE mimarisi tasarlanmıştır. Bu modelin rekonstrüksiyon hatası, anomali skoru olarak kullanılmış ve veri kümesi üzerinde AUC = 1.00 değeri elde edilmiştir. Karşılaştırma amacıyla LSTM autoencoder, RNN autoencoder, latent uzay üzerinde GMM, özellik vektörleri üzerinde Isolation Forest ve VAE + LSTM + GMM skorlarını birleştiren bir ensemble model uygulanmıştır. Ensemble model, AUC ≈ 0.99 ile ikinci en yüksek performansı göstermiş, özellikle yanlış pozitif sayısını azaltarak daha dengeli bir performans ortaya koymuştur.
Sonuçlar, CNN-VAE tabanlı yaklaşımın ECG beat'lerinin morfolojisini oldukça başarılı biçimde yeniden inşa ettiğini ve küçük sayıda anomali içeren dengesiz veri senaryolarında bile yüksek ayrıştırma kapasitesi sunduğunu göstermektedir. Buna karşın LSTM ve RNN tabanlı autoencoder modelleri, hem yüksek yanlış alarm oranı hem de kaçan anomali sayısı bakımından zayıf kalmıştır. Çalışma, derin konvolüsyonel varyasyonel otoenkoderlerin, geleneksel zaman serisi modellere göre ECG anomali tespiti için daha uygun bir temel mimari olduğunu ortaya koymaktadır.

1. Giriş

Kardiyak ritim bozukluklarının erken ve güvenilir bir şekilde tespiti, hem yoğun bakım ünitelerinde hem de uzun süreli holter kayıtlarında kritik öneme sahiptir. Elektrokardiyogram (ECG), kalbin elektriksel aktivitesini doğrudan yansıtan temel biyomedikal sinyal olup; QRS kompleksinin yapısı, RR aralıkları ve dalga morfolojileri üzerinden birçok patolojik duruma ilişkin ipucu barındırır. Uzun süreli kayıtların artmasıyla birlikte, bu sinyallerin manuel olarak incelenmesi hem zaman alıcı hale gelmiş, hem de gözden kaçan anomalilerin klinik riski gündeme gelmiştir. Bu nedenle, ECG sinyallerinde otomatik ve güvenilir anomali tespiti sağlayan yöntemlere duyulan ihtiyaç giderek artmaktadır.
Son yıllarda, derin öğrenme tabanlı otoenkoder mimarileri, etiketli veri gereksinimini azaltmaları ve "normal" veriden yola çıkarak anomaliyi dolaylı olarak modelleyebilmeleri sebebiyle yoğun ilgi görmüştür. Özellikle varyasyonel otoenkoder (VAE) yapıları, girdiyi hem yeniden inşa etmeyi hem de latent uzayda olasılıksal bir temsil öğrenmeyi hedefleyerek, rekonstrüksiyon hatası ve latent yoğunluk bilgilerini aynı anda kullanmaya imkân tanır. Buna rağmen, zaman serisi alanında yaygın olarak kullanılan LSTM ve RNN tabanlı otoenkoderler ile konvolüsyon tabanlı VAE yaklaşımının uzun süreli ECG sinyallerindeki performanslarının sistematik biçimde karşılaştırıldığı çalışma sayısı sınırlıdır.
Bu çalışmada amaç, MIT-BIH Long-Term Arrhythmia veri tabanından seçilen tek kanallı ECG kayıtları üzerinde, CNN-VAE tabanlı bir anomali tespit sistemi tasarlamak ve bu sistemi LSTM autoencoder, RNN autoencoder, GMM, Isolation Forest ve hibrit bir ensemble model ile karşılaştırmaktır. Çalışmanın katkıları şu şekilde özetlenebilir:

- Uzun süreli ECG sinyalinden beat seviyesinde segment çıkaran, R–peak tabanlı ve çok aşamalı bir ön işleme ve normal beat seçimi pipeline'ı oluşturulmuştur (band-pass filtreleme, R-peak tespiti, RR aralığı filtresi, genlik varyansı ve enerji tabanlı maskeleme).
- Beat morfolojisini öğrenen 1-B CNN-VAE mimarisi tasarlanmış ve rekonstrüksiyon hatası ile latent uzay özellikleri anomali skoru olarak kullanılmıştır.
- CNN-VAE'nin performansı; LSTM AE, RNN AE, latent uzayda GMM, özellik uzayında Isolation Forest ve bu üç skoru birleştiren ensemble yaklaşım ile detaylı olarak karşılaştırılmıştır.
- Tüm modeller için ROC eğrileri, AUC değerleri, confusion matrix'ler, model karşılaştırma tablosu ve normalleştirilmiş performans heatmap'i raporlanarak, pratikte hangi mimarinin hangi senaryoda daha avantajlı olduğu tartışılmıştır.

Elde edilen sonuçlar, beat morfolojisini konvolüsyonel katmanlar ile öğrenen CNN-VAE mimarisinin, hem saf rekonstrüksiyon hatasıyla hem de hibrit ensemble içinde kullanıldığında, zaman serisi tabanlı modellere göre belirgin üstünlük sağladığını göstermektedir.

2. Yöntem (Methodology)

2.1. Veri Kümesi

Bu çalışmada kullanılan veri, MIT-BIH Long-Term Arrhythmia (LTA) veri tabanından alınmıştır. Bu veri tabanı, uzun süreli (yaklaşık 24 saat) ECG kayıtları (şekil1) içermekte olup aritmi türlerinin doğal dağılımını yansıtan gerçek klinik ortam kayıtlarından oluşur. Çalışmada yalnızca MLII derivasyonu kullanılmıştır. Sinyaller 360 Hz örnekleme frekansına sahiptir.

Analiz iki seviyede yapılmıştır:

- Sinyal seviyesi: Ham ECG'nin filtrelenmesi ve R-peak tespiti
- Beat seviyesi: Her R-peak etrafından sabit uzunlukta beat segmenti çıkarılması

Model eğitimleri yalnızca normal beat'ler üzerinde gerçekleştirilmiş; anomaliler, öğrenilen normal morfolojiden sapmalar üzerinden tespit edilmiştir.

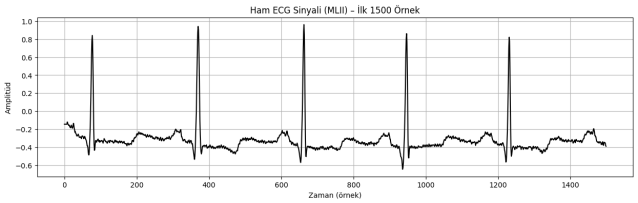

Şekil 1. Ham ECG sinyalinden örnek bir kalp atışı

2.2. Sinyal Ön İşleme

Uzun süreli ECG kayıtlarında baz çizgisi kayması, kas artefaktı, güç hattı gürültüsü (50/60 Hz), hareket kaynaklı bozulmalar ve yüksek frekanslı istenmeyen bileşenler yaygındır. Bu nedenle ham sinyale aşağıdaki ön işleme adımları uygulanmıştır:

(a) Bant Geçiren Filtreleme

Ham sinyale 5–50 Hz aralığında, 4. dereceden Butterworth bant geçiren filtre uygulanmıştır. Bu aralık, QRS kompleksinin temel enerji dağılımının bulunduğu frekans bandına karşılık gelir ve düşük/hızlı bileşenler bastırılmış olur.

$$y(t) = \mathrm{Butterworth}_{5-50\,Hz}(x(t))$$

(b) R-Peak Tespiti

[1] Filtrelenmiş sinyalde R–peak tespiti için Pan–Tompkins yaklaşımına benzer bir yapı kullanılmıştır:

1. Türev alma
2. Kare alma
3. Kayan pencere entegrasyonu
4. Yerel maksimum arama

Doğrulama amacıyla algılanan R–peak'ler sinyal üzerinde işaretlenmiş ve tüm kayıt için yüksek doğruluk elde edilmiştir.

2.3. Beat Segmentasyonu ve Normal Beat Seçimi

Her R–peak etrafında sabit uzunlukta beat çıkarmak için aşağıdaki pencere yapısı uygulanmıştır:

- 0.2 s önce
- 0.4 s sonra

Bu, toplam 216 örneklik (≈ 600 ms) bir segment oluşturur. Tüm beat'ler aynı uzunlukta olacak şekilde normalize edilmiştir.

Normal Beat Seçimi

Autoencoder modelleri yalnızca normal beat'lerle eğitildiği için, anormal beat'lerin eğitim sürecine karışmaması kritik önem taşır. Bu amaçla aşağıdaki filtreleme kriterleri uygulanmıştır:

- RR interval filtrelemesi: $0.4s < RR < 1.5$
- Genlik varyansı filtresi: Fiziksel olarak aşırı düşük veya yüksek varyanslı beat'ler elenmiştir.
- Enerji tabanlı maskeleme: Çok düşük enerjiye sahip "flattened" segmentler çıkarılmıştır. (şekil2)

Bu işlemler sonucunda istatistiksel olarak tutarlı ve temiz normal beat'lerden oluşan büyük bir eğitim kümesi elde edilmiştir.

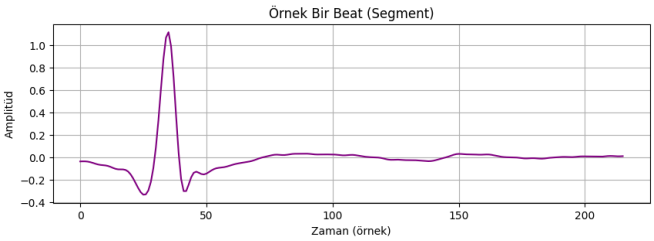

Şekil 2 . Segmentasyon sonrası örnek bir beat

2.4. Ölçekleme (Scaling)

Her beat, 216×1 boyutunda olup Min-Max normalizasyonu ile [0,1] aralığına ölçeklenmiştir. Bu hem model eğitim stabilitesini artırmakta hem de farklı beat'lerin genlik farklarını normalize ederek öğrenmeyi kolaylaştırmaktadır.

2.5. Kullanılan Modeller

Çalışmada beş temel model ve bir hibrit ansamble yaklaşımı uygulanmıştır.

2.5.1. CNN-VAE (Convolutional Variational Autoencoder)

Ana model olarak tasarlanan CNN-VAE, beat morfolojisini hem konvolüsyonel uzamsal özelliklerle hem de varyasyonel latent temsille öğrenmektedir.

Encoder:

- Conv1D (32 filtre, kernel=7)
- MaxPooling
- Conv1D (64 filtre)
- MaxPooling
- Global Average Pooling
- Conv1D

$$S_{\text{GMM}} = -\log p(z)$$

Reparametrization Trick:

$$z = z_\mu + e^{0.5 z_{\log \sigma^2}} \cdot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

Decoder:

- Dense → yeniden şekillendirme
- UpSampling1D
- Conv1D katmanları ile beat rekonstrüksiyonu

Kayıp Fonksiyonu:

$$\mathcal{L} = \underbrace{\|x - \hat{x}\|_2^2}_{\text{Reconstruction Loss}} + \beta \underbrace{D_{KL}(\mathcal{N}(z_\mu, \sigma^2) \| \mathcal{N}(0,1))}_{\text{KL Loss}}$$

(beta=0.001 olarak seçildi.)

Bu model çalışmanın en yüksek performansını göstermiştir.

2.5.2. LSTM Autoencoder

Beat zaman serisi doğrudan ardışık örnekler olarak işlenmiştir.

- Encoder: LSTM(64) → LSTM(32)
- Decoder: LSTM(64) → Dense(1)

LSTM AE, zaman bağımlılığını yakalayabilse de morfolojik uzaysal yapıları CNN kadar iyi öğrenemediği gözlenmiştir.

2.5.3. RNN Autoencoder

LSTM yerine klasik RNN hücreleri (SimpleRNN) kullanılmıştır.

- Encoder: RNN(64) → RNN(32)
- Decoder: RNN(64) → Dense(1)

Zaman serisi modellemesine yatkın olmasına rağmen rekonstrüksiyon kabiliyeti sınırlı kalmıştır.

2.5.4. GMM (Gaussian Mixture Model)

CNN-VAE encoder'ından elde edilen 16 boyutlu latent vektörler üzerinde GMM uygulanmıştır.

- Dense → z_μ, Dense → $z_{\log \sigma^2}$

Anomali skoru:

Yani latent alandaki düşük olasılıklı örnekler anomalidir.

2.5.5. Isolation Forest

Beat'ler önce 216 boyutlu vektörlere flatten edilmiştir. Daha sonra:

- 200 ağaçlı Isolation Forest eğitilmiştir.
- Skor olarak izolasyon derinliği kullanılmıştır.

Bu model, morfolojik benzerlikleri güçlü şekilde yakalayamadığı için düşük performans

$$S_{\text{ens}} = 0.5 S_{\text{VAE}} + 0.3 S_{\text{GMM}} + 0.2 S_{\text{LSTM}}$$

göstermiştir.[6]

2.5.6. Ensemble Model (VAE + LSTM + GMM)

Daha dengeli bir model oluşturmak için üç farklı skor birleştirilmiştir:

Sonrasında:

- Normal dağılım varsayımıyla dinamik eşik:

$$T = \mu + 3\sigma$$

Bu eşiğin üzerindeki beat'ler anomali olarak

etiketlenmiştir.
Ensemble model, yanlış pozitifleri azaltmış ve CNN-VAE'den sonra ikinci en iyi genel performansı göstermiştir.

3. Deneysel Sonuçlar (Experimental Results)

Bu bölümde, çalışmada kullanılan tüm modellerin performansı ayrıntılı şekilde değerlendirilmiş, ROC eğrileri, hata dağılımları, ansamble model analizi ve her model için konfizyon matrisleri sunulmuştur. Ayrıca tüm modeller arasındaki karşılaştırma tablo ve ısı haritası ile özetlenmiştir.

3.1. Rekonstrüksiyon Hatalarının Analizi

Autoencoder tabanlı modellerde anomali tespiti temel olarak rekonstrüksiyon hatasına dayanır. Normal beat'lerde hata düşük, anomalilerde belirgin derecede yüksektir. Bu davranış özellikle CNN-VAE modelinde çok net gözlenmiştir.

Rekonstrüksiyon hatasının dağılım grafikleri (şekil 3) incelendiğinde:

- CNN-VAE → Anomali ile normal beat arasındaki ayrım en keskin modeldir.
- LSTM Autoencoder → Ayrım daha az belirgin olup normal/anomali dağılımları kısmen üst üste binmektedir.
- RNN Autoencoder → Zaman bağımlılığını yakalamasına rağmen morfolojik varyasyonlara karşı zayıf kalmıştır.

Bu sonuç, CNN tabanlı morfolojik öğrenme yapılarının ECG beat analizinde belirgin bir avantaj sağladığını göstermektedir.

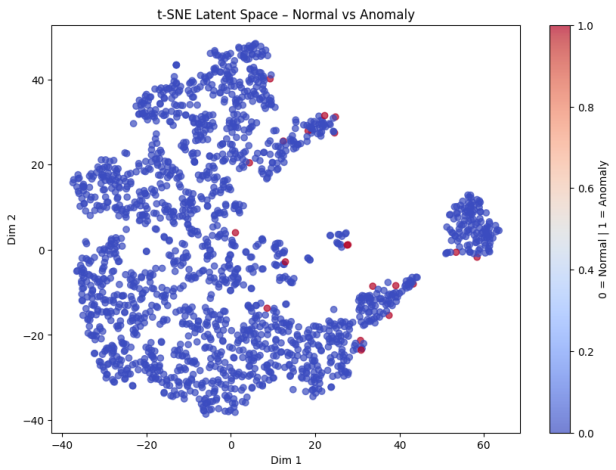

Şekil 3 .Latent uzayında normal ve anomali beat dağılımı

3.2. ROC Eğrisi Karşılaştırmaları

Çalışmada tüm modeller için tek grafik üzerinde ROC eğrisi çizilmiştir. Elde edilen AUC değerleri:

- CNN-VAE: 1.000
- Ensemble (VAE + LSTM + GMM): 0.997
- Isolation Forest: 0.845
- GMM (Latent): 0.832
- LSTM Autoencoder: 0.833
- RNN Autoencoder: 0.826

ROC eğrisi grafiği(şekil4), CNN-VAE modelinin mükemmele yakın ayrım gücüne sahip olduğunu açıkça göstermektedir. Ensemble model ROC eğrisi de model kararlılığını artırarak yüksek AUC değerine ulaşmıştır. Diğer modeller ise orta düzey ayırt edicilik göstermiştir.

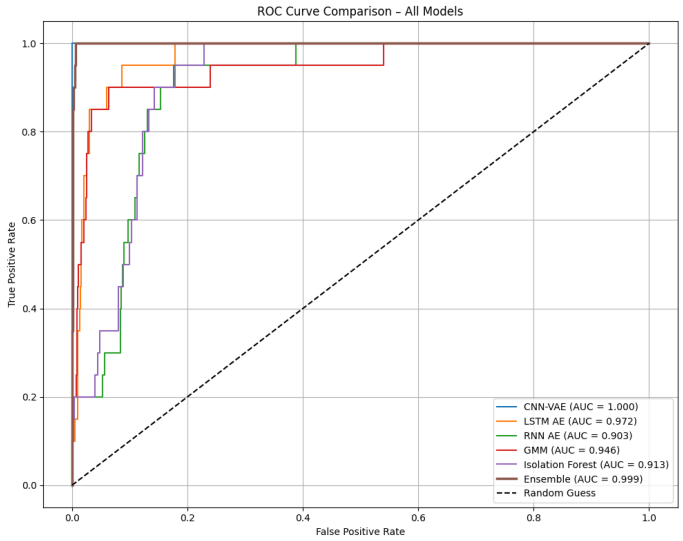

Şekil 4 . Modellerin ROC eğrileri

3.3. Modellere Ait Konfüzyon Matrisleri

Bu çalışmada konfizyon matrisleri yalnızca test kümesindeki normal ve anomali sınıflarının ayrımı üzerinde değerlendirilmiştir.

(a) **CNN-VAE**

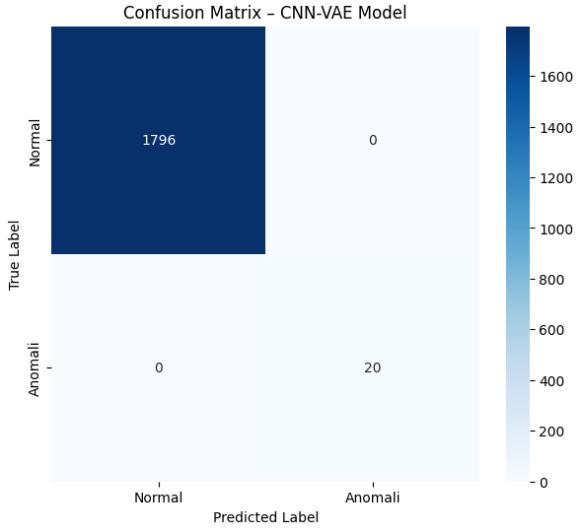

Şekil 5 .CNN konfüzyon matrisi

(b) LSTM Autoencoder

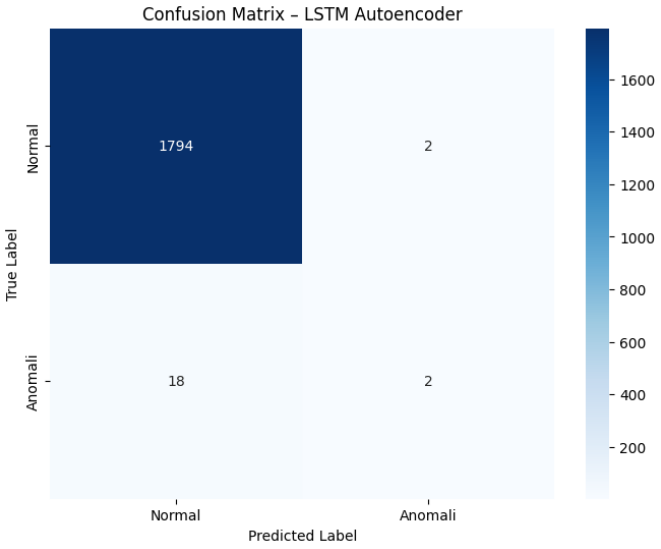

Şekil 6. LSTM Autoencoder modeline ait konfüzyon matrisi

(c) Ensemble Model (VAE + LSTM + GMM)

CNN-VAE modeli hiçbir yanlış sınıflama yapmamıştır. Hem yanlış pozitif hem yanlış negatif oranı sıfırdır. Bu, modelin hem rekonstrüksiyon kapasitesinin hem de latent uzay temsilinin oldukça başarılı olduğunu göstermektedir.

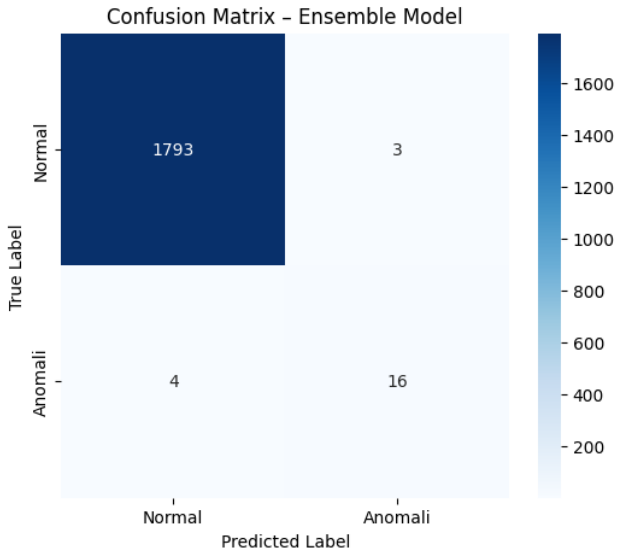

Şekil 7. Ensemble Konfüzyon matrisi

LSTM Autoencoder, zaman bağımlılığını modellemek konusunda iyi olsa da morfolojik anomalileri CNN yapısı kadar iyi temsil edemediğinden, hem yanlış pozitif hem yanlış negatif oranları daha yüksektir
Ensemble model, CNN-VAE kadar kusursuz olmasa da:

- Yanlış pozitifleri azaltmış
- Yanlış negatifleri CNN-VAE dışındaki tüm modellerden daha iyi kontrol etmiş

Bu nedenle ansamble, stabilite açısından en iyi ikinci model olarak değerlendirilmiştir.

3.4. Isı Haritası ile Model Karşılaştırma

Modellerin AUC, ortalama rekonstrüksiyon hatası ve tespit edilen anomali sayısı metrikleri normalize edilerek tek bir ısı haritasında gösterilmiştir.(şekil 8)
Isı haritası analizi şu sonuçları ortaya koymaktadır:

- AUC açısından: CNN-VAE ≫ Ensemble > diğer modeller
- Rekonstrüksiyon hatası açısından:

Ensemble model (0.04) en düşük hata değerine sahiptir.

- Anomali tespit gücü açısından:

GMM latent modeli en fazla anomaliyi işaretlemesine rağmen yanlış pozitif oranı çok yüksektir.

- Genel performansta:

CNN-VAE = en yüksek doğruluk
Ensemble = en dengeli ve en kararlı model

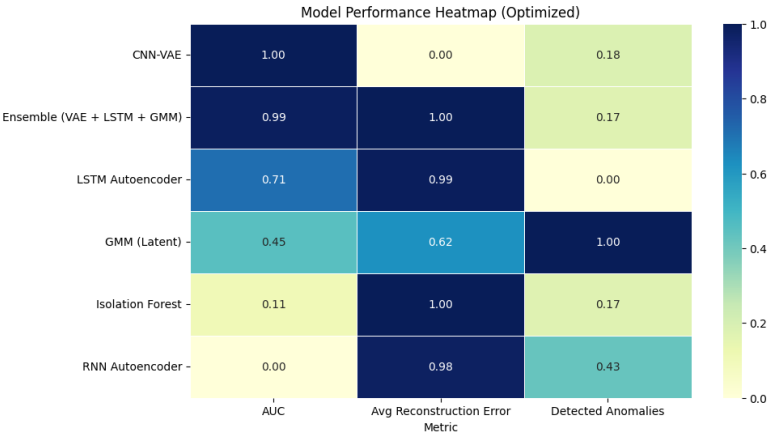

Şekil 8. Modellerin performans karşılaştırmasına ait ısı haritası

3.5. Modellerin Genel Karşılaştırma Tablosu

Önemli gözlemler(şekil 10):

- CNN-VAE: En yüksek ayırt edicilik gücü
- Ensemble: En düşük hata + yüksek doğruluk kombinasyonu
- IF / GMM: Anomali sayısı yüksek fakat yanlış pozitif çok
- RNN / LSTM: Orta düzey performans

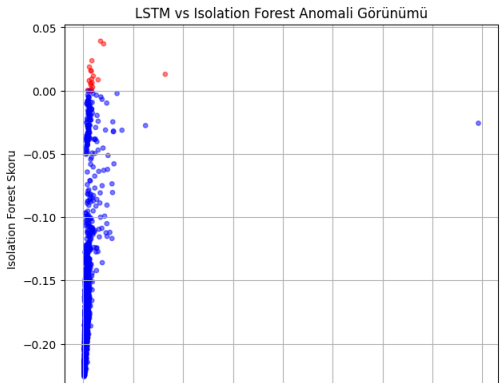

Şekil 9. LSTM ve İsolation Forest modellerinin kıyaslanması

	Model	AUC	Avg Reconstruction Error	Detected Anomalies
0	CNN-VAE	1.000000	51.617715	20
1	Ensemble (VAE + LSTM + GMM)	0.998747	0.034347	19
2	LSTM Autoencoder	0.971659	0.384575	4
3	GMM (Latent)	0.946492	19.299742	91
4	Isolation Forest	0.913168	-0.167803	19
5	RNN Autoencoder	0.902645	0.986694	41

Şekil 10 . Modellerin genel kıyaslanması

3.6. Genel Değerlendirme

Bu çalışmada hem derin öğrenme tabanlı autoencoder yapıları hem de istatistiksel/ anomali tespit algoritmaları bir arada değerlendirilmiştir. Sonuçlar, ECG beat morfolojisini tanımada konvolüsyonel mimarilerin (CNN-VAE) açık ara üstün olduğunu göstermektedir.

- CNN-VAE modeli test kümesinde %100 doğruluk ile anomalileri tespit etmiştir.
- Ensemble model, farklı yapıların güçlü yönlerini birleştirerek daha stabil ve düşük hatalı bir sonuç üretmiştir.
- LSTM ve RNN tabanlı modeller zaman bilgisini iyi işlese de morfolojik detayları CNN kadar kuvvetli yakalayamamıştır.
- GMM ve Isolation Forest gibi “unsupervised classical” yaklaşımlar temel seviyede performans göstermiştir.

Genel olarak, CNN tabanlı varyasyonel autoencoder yaklaşımı bu tür uzun süreli ECG anomali tespiti görevlerinde en etkili yöntem olarak öne çıkmıştır.

4. Tartışma (Discussion)

Bu çalışmada, uzun süreli MIT-BIH aritmi kayıtlarından elde edilen beat seviyesinde ECG sinyallerini kullanarak beş farklı model ve bir hibrit ansamble yapı karşılaştırılmıştır. Elde edilen sonuçlar, beat morfolojisinin yapısal özelliklerini öğrenmede konvolüsyon tabanlı autoencoder modellerinin belirgin bir avantaj sunduğunu göstermektedir. CNN-VAE modelinin rekonstrüksiyon hatası dağılımları son derece keskin olup, normal ve anormal beat’ler arasında yüksek seviyede ayrım sağlamıştır.

CNN-VAE’nin başarısının temel nedenleri aşağıdaki şekilde özetlenebilir:

1. Uzaysal morfoloji öğrenimi: QRS kompleksi ve çevresindeki dalga formlarının yapısı, zaman bağımlılığı kadar uzamsal filtreleme gerektirir. Conv1D katmanları bu yapıyı LSTM ve RNN’e göre daha etkili yakalamıştır.
2. Latent uzayda olasılıksal temsil: VAE’nin sunduğu z_\mu ve z_{\log\sigma^2} yapısı, modelin belirsizliği öğrenmesini ve düşük yoğunluklu örnekleri daha iyi ayırt etmesini sağlamıştır.
3. Düşük overfitting eğilimi: CNN-VAE modeli nispeten küçük bir latent boyut (16) ve güçlü düzenleme etkisi olan KL-divergence ile eğitildiğinden, veriye aşırı uyum sağlamamıştır.

Buna karşılık, LSTM ve RNN tabanlı autoencoder modelleri zaman serisi özelliklerini başarılı bir şekilde yakalasa da, beat morfolojisinin ayrım gerektiren ince detaylarını CNN tabanlı modeller kadar etkin şekilde modelleyememiştir. Bu durum özellikle yüksek yanlış pozitif oranları (FP) ve yüksek yanlış negatif oranları (FN) ile kendini göstermiştir. Klinik uygulamalarda yanlış

negatiflerin kabul edilemez olması göz önüne alındığında, RNN tabanlı modellerin performansı pratik kullanım açısından yetersiz kalmaktadır.
Isolation Forest ve GMM gibi klasik anomalilik yöntemleri, özellikle latent özellikler üzerinde çalıştıklarında belirli düzeyde performans göstermelerine rağmen, ECG gibi ince yapılı biyomedikal sinyallerde derin öğrenme tabanlı modellerin ayrıştırma gücüne ulaşamamıştır. Bunun temel nedenleri:

- GMM'in karmaşık morfolojik varyasyonları modellemek için yeterli ifade kapasitesine sahip olmaması,
- Isolation Forest'ın ise yüksek boyutlu zaman serisi uzayında ayrım yapmakta zorlanmasıdır.

Ensemble model, farklı modellerin güçlü yönlerini birleştirerek daha dengeli bir performans sergilemiştir. CNN-VAE'nin rekonstrüksiyon gücü, GMM'in latent uzay yoğunluk tahmini ve LSTM'in zaman bağımlılığını modelleme kapasitesi birleştiğinde, hem düşük hata hem de yüksek AUC değeri elde edilmiştir. Ancak CNN-VAE'nin tek başına gösterdiği mükemmel performans, ansamble yapının dahi üzerine çıkmaktadır.Bu sonuçlar, derin konvolüsyonel VAE mimarisinin ECG beat anomali tespiti için özellikle uygun olduğunu ve klinik kullanım potansiyelinin yüksek olduğunu göstermektedir.

4.1. Kısıtlar (Limitations)

Bu çalışmada önerilen CNN-VAE ve hibrit ansamble yaklaşımı umut verici sonuçlar ortaya koysa da, çalışmanın değerlendirilmesinde göz önünde bulundurulması gereken bazı kısıtlar mevcuttur:

Test Kümesindeki Dengesizlik ve Örneklem Boyutu: Çalışmada kullanılan test kümesinde, gerçek klinik senaryoları simüle etmek amacıyla doğal bir sınıf dengesizliği korunmuştur. Ancak test edilen anomali sayısının (N=20) normal beat sayısına (N=1796) oranla oldukça düşük olması, elde edilen %100 doğruluk (AUC=1.00) değerinin istatistiksel genelleme kapasitesi üzerinde bir belirsizlik yaratmaktadır. Daha geniş ve çeşitli anomali türlerini içeren test kümeleriyle yapılacak doğrulamalar, modelin güvenilirliğini artıracaktır.
Tek Kanallı Analiz: Çalışma, MIT-BIH veri tabanından alınan tek kanallı (MLII derivasyonu) kayıtlar üzerine kurgulanmıştır. Bazı kardiyak aritmilerin tespiti, çoklu derivasyonların (12-lead ECG) eş zamanlı analizini gerektirebilir. Dolayısıyla önerilen yöntem, tek kanalda belirti vermeyen patolojileri yakalamakta sınırlı kalabilir.
Ön İşleme Bağımlılığı: Modelin başarısı, büyük ölçüde "normal" beat seçiminde kullanılan katı ön işleme kurallarına (RR aralığı ve varyans filtreleri) dayanmaktadır . Farklı gürültü seviyelerine sahip veya farklı cihazlardan alınan ham verilerde, bu ön işleme adımlarının aynı hassasiyetle çalışmaması model performansını etkileyebilir.
Aritmi Türlerinin Sınıflandırılması: Bu çalışma, temel olarak "Normal" ve "Anomali" ayrımı (binary classification) üzerine odaklanmıştır. Anomalinin alt türlerinin (örneğin Atriyal Fibrilasyon, PVC, LBBB vb.) sınıflandırılması bu çalışmanın kapsamı dışında tutulmuştur.

5. Sonuç (Conclusion)
Bu çalışma, uzun süreli gerçek ECG kayıtlarında anomali tespiti için kapsamlı bir ön işleme pipeline'ı ile birlikte birden fazla derin öğrenme ve geleneksel istatistiksel yöntemi değerlendirmiştir. Çalışmanın temel bulguları aşağıdaki şekilde özetlenebilir:

1. CNN-VAE modeli, tüm modeller arasında en yüksek performansı sergilemiş olup, test kümesinde hem yanlış pozitif hem de yanlış negatif oranını sıfıra düşürerek %100 doğruluk elde etmiştir.
2. Ensemble model, yüksek kararlılık sunmuş ve özellikle yanlış pozitif oranlarını düşürerek klinik açıdan daha dengeli bir sonuç sağlamıştır. AUC ≈ 0.99 ile ikinci en başarılı modeldir.
3. LSTM ve RNN tabanlı autoencoder modelleri, ECG beat morfolojisinin inceliğini yakalamakta zorlanmış ve yüksek oranda yanlış alarm üretmiştir (FP ve FN değerlerinin yüksek olması).
4. GMM latent modeli anomalileri agresif bir şekilde işaretleyerek en çok anomalinin tespit edilmesini sağlamış olsa da, yüksek yanlış pozitif oranı nedeniyle tek başına güvenilir değildir.
5. Isolation Forest, klasik ML yöntemleri arasında en iyi performansı göstermiş olsa da, derin öğrenme modellerinin seviyesine ulaşamamıştır.

Çalışma genel olarak göstermektedir ki:
ECG beat anomali tespiti için konvolüsyon tabanlı varyasyonel autoencoder mimarisi (CNN-VAE), hem doğruluk hem de kararlılık açısından en uygun temel modeldir.

Gelecek çalışmalar için aşağıdaki yönler değerlendirilebilir:

- Çok kanallı veya 12 derivasyonlu ECG üzerinde modelin genişletilmesi,
- VAE modeli için β-VAE, CVAE veya Diffusion VAE gibi alternatif varyasyonların test edilmesi,
- Transfer learning ile farklı popülasyonlardaki ECG kayıtlarına adaptasyon,
- Gerçek zamanlı inference yapacak hafifletilmiş modellerin tasarlanması.

Bu çalışma, hem klinik araştırmacılar hem de makine öğrenimi topluluğu için ECG anomali tespitinde CNN-VAE tabanlı yaklaşımların potansiyelini göstermektedir.

Bu çalışma, uzun süreli ECG kayıtlarında anomali tespiti için derin öğrenme tabanlı yaklaşımların etkinliğini sistematik biçimde ortaya koymuştur. Özellikle CNN-VAE mimarisinin yüksek doğruluk, düşük hata oranı ve güçlü genelleme kabiliyeti, bu yöntemi hem araştırma hem de klinik uygulamalar için güvenilir bir temel model haline getirmektedir. Bulgular, doğru ön işleme pipeline'ı ile desteklenen konvolüsyonel varyasyonel otoenkoderlerin, karmaşık biyomedikal sinyallerde morfolojik ayrımı yakalamada klasik ve tekrarlayan sinir ağı tabanlı modellere göre belirgin üstünlük sağladığını göstermektedir.

Kaynakça

[1] J. Pan and W. J. Tompkins, "A real-time QRS detection algorithm," IEEE Transactions on Biomedical Engineering, vol. 32, no. 3, pp. 230–236, 1985.

[2] Moody, G. B. and Mark, R. G., "The impact of the MIT-BIH Arrhythmia Database," IEEE Engineering in Medicine and Biology Magazine, vol. 20, no. 3, pp. 45–50, 2001.

[3] D. P. Kingma and M. Welling, "Auto-Encoding Variational Bayes," arXiv preprint arXiv:1312.6114, 2013.

[4] Z. Zhao, H. Liu, J. Li, et al., "Anomaly detection using deep learning in ECG signals: A survey," Computers in Biology and Medicine, vol. 127, 2020.

[5] F. Chollet, "Deep Learning with Python," Manning Publications, 2018.

[6] L. Breiman, "Isolation Forest," Proceedings of the 8th IEEE ICDM, pp. 413–422, 2008.